

DOKUMENTACJA SPECYFIKACJI WYMAGAŃ

Projekt zaliczeniowy: Michał Kośka, Alicja Topór, Jakub Pańczak¹

1. WPROWADZENIE

Celem naszego systemu jest eksploracja danych tekstowych (text mining) oraz analiza ewolucji narracji makroekonomicznej prezesa NBP, prof. Adama Glapińskiego w latach 2016-2026. Nasz projekt ma rozwiązywać problem czasochłonnej i manualnej analizy długich wystąpień publicznych szefa NBP.

System operuje na danych wyjściowych w postaci surowych plików tekstowych .txt zawierających transkrypcje konferencji prasowych, przygotowanych przez dedykowany skrypt w języku Python. Wykorzystuje również zewnętrzną listę wyrazów, które może pomijać (stopwords.txt) oraz rejestr wskaźników inflacji GUS w formacie .csv.

System izoluje wypowiedzi najczęstszego mówcy (zakładamy, iż jest to prof. Glapiński) oraz dokonuje wielowątkowej tokenizacji i lematyzacji tekstu do form słownikowych. Zachodzi również automatyczne oczyszczanie tekstu z szumu gramatycznego. Kod konsoliduje również utarte, wielowyrazowe frazy w jednolite tokeny (np. "punkt_procentowy").

Wyniki końcowe są prezentowane w postaci interaktywnego raportu HTML zintegrowanego z silnikiem Shiny. Użytkownik otrzymuje chmurę stu najpopularniejszych słów, wykres prezentujący trendy retoryczne na tle historycznej inflacji oraz interaktywny panel do badania siły asocjacji przy użyciu korelacji Pearsona.

Zgodnie z podejściem Reproducible Research, całe środowisko/system zapewnia pełną powtarzalność i odtwarzalność przeprowadzonych analiz statystycznych.

¹ Podział obowiązków zamieściliśmy na ostatniej stronie dokumentu.

2. CELE SYSTEMU

- **Automatyczna izolacja kluczowych danych:** identyfikacja kluczowego mówcy (prof. Glapińskiego) na podstawie heurystyki największej częstotliwości wystąpień w tekście źródłowym oraz usunięcie wypowiedzi innych osób
- **Lematyzacja:** wielowątkowa lematyzacja z wykorzystaniem narzędzia *udpipe* rozwijanego przez Instytut Lingwistyki Formalnej i Stosowanej z Uniwersytetu Karola w Pradze
- **Przetwarzanie tekstowe:** oczyszczenie korpusu, tj. usunięcie interpunkcji, liczb, partykuł, zaimków, wykrzykników, form grzecznościowych, stopwords
- **Manualna konsolidacja frazeologiczna:** identyfikacja i scalanie wielowyrazowych, utartych zwrotów makroekonomicznych (np. “rada polityki pieniężnej”, “punkt procentowy”) w pojedyncze tokeny w celu zachowania ich sensu semantycznego
- **Strukturyzacja danych w Modelu Bag of Words:** utworzenie macierzy TDM i chmury słów
- **Eksploracja częstości i trendów:** Wyznaczenie pojęć najczęściej występujących oraz badanie zmian retoryki wybranych słów w czasie (z uwzględnieniem okresu pandemii COVID-19)
- **Analiza asocjacji:** obliczanie współczynnika korelacji Pearsona dla wybranych pojęć
- **Interaktywna wizualizacja:** wygenerowanie interaktywnego raportu HTML zawierającego chmurę słów, czasowe wykresy trendów oraz sterowalny panel do wykrywania asocjacji

3. WYMAGANIA FUNKCJONALNE

- System musi wczytywać transkrypcje konferencji prasowych prezesa NBP (w formacie .txt) i wyodrębniać datę konferencji z nazwy każdego pliku, przypisując ją jako identyfikator dokumentu
- System musi analizować rozkład znaczników mówców i wskazywać identyfikator tego mówcy, który posiada największą liczbę wypowiedzi (zakładamy, iż prezes NBP mówi na konferencjach najczęściej)
- System musi odrzucać wszystkie linie tekstu należące do innych mówców (pozostawiając tylko wypowiedzi prezesa NBP – zgodnie z przyjętym założeniem)
- System musi przeprowadzać lematyzację przy użyciu modelu *udpipe* (pakietu *polish-pdp*)
- System musi usuwać z korpusu tokeny sklasyfikowane przez model *udpipe* (klasyfikacja UPOS) jako znaki interpunkcyjne (PUNCT), liczby (NUM), partykuły (PART), zaimki określające (DET), wykrzykniki (INTJ) oraz formuły grzecznościowe i tzw. stopwords
- System musi scalać wskazane w kodzie wielowyrazowe zwroty instytucjonalne i makroekonomiczne w pojedyncze tokeny (np. zmiana “rada polityki pieniężnej” na jeden token “RPP” lub zmiana “punkt procentowy” na “punkt_procentowy”)
- System musi transformować przetworzony korpus do postaci macierzy TDM i wyliczać częstość występowania słów
- System musi umożliwiać wczytanie pliku z danymi dot. inflacji w formacie .csv, zliczać częstość wystąpienia podanych w kodzie słów-kluczy i nakładać je na liniowy wykres inflacji
- System musi generować statyczną chmurę słów prezentującą maksymalnie 100 najpopularniejszych słów/wyrażeń
- System musi udostępniać użytkownikowi interaktywne menu zawierające listę słów, które w całym korpusie wystąpiły co najmniej 10 razy; musi udostępniać użytkownikowi interaktywny suwak pozwalający na dynamiczną zmianę progu korelacji w przedziale od 0.1 do 0.9
- System musi wizualizować wyniki za pomocą: chmury słów, wykresu liniowego, wykresu segmentowo-punktowego prezentującego max. 15 najsilniej skorelowanych słów
- System powinien umożliwiać wygenerowanie raportu HTML z widocznym spisem treści i możliwością zwijania kodu w raporcie.

4. WYMAGANIA NIEFUNKCJONALNE

- **Reproducibility:** Kod źródłowy i dane wejściowe muszą być dostępne w formie pozwalającej na łatwe powtórzenie analizy (u nas: na platformie GitHub)
- **Wydajność:** Cały kod (w tym wielowątkowa lematyzacja czy budowanie macierzy) powinien być zoptymalizowanym, aby jego uruchomienie na standardowym komputerze osobistym trwało jak najmniej.
- **Niezawodność:** System powinien działać stabilnie dla różnych zestawów danych wejściowych, samodzielnie obsługiwać błędy, zapobiegając awariom potoku danych.
- **Łatwość użycia:** Skrypt powinien być łatwy do uruchomienia, a wyniki powinny być estetyczne i czytelne (np. wykresy powinny posiadać czytelne tytuły, legendy, etykiety, wartości)
- **Bezpieczeństwo:** System musi działać na stacji roboczej użytkownika i nie może przysyłać danych do zewnętrznych usług. Nie powinien przechowywać poufnych informacji.
- **Kompatybilność:** Skrypt musi być kompatybilny ze środowiskiem R (w wersji 4.0 lub nowszej) oraz współpracować z bibliotekami zarządzanymi przez pakiet pacman (tidyverse, tidytext, tm, wordcloud, udpipe, futurem furr, shiny)

5. INTERFEJSY UŻYTKOWNIKA I WYMAGANIA DOTYCZĄCE DANYCH

DANE WEJŚCIOWE (INPUT):

- a) System przyjmuje dane tekstowe w postaci plików tekstowych o rozszerzeniu .txt. Każdy plik zawiera pełną transkrypcję konferencji prasowej z zakodowanymi znacznikami mówców (np. [SPEAKER_00]). Nazwa pliku musi odpowiadać dacie konferencji.
- b) Plik tekstowy stopwords.txt zawierający listę polskich słów przeznaczonych do wykluczenia z analizy częstości.
- c) Plik .csv pobierany z baz danych GUS, zawierający poziomy wskaźnika inflacji.
- d) Plik Zrodla.txt zawierający spis literatury i materiałów źródłowych.

INTERFEJS UŻYTKOWNIKA:

- a) Użytkownik rozpoczyna działanie systemu z poziomu środowiska RStudio poprzez uruchomienie renderowania dokumentu R Markdown.
- b) Po skompilowaniu kodu użytkownik zarządza analizą asocjacji za pomocą interaktywnych elementów sterujących: listy zawierającej lematy, które pojawiły się w korpusie minimum 10 razy oraz suwaga z progiem korelacji.
- c) Użytkownik może wchodzić w interakcję z raportem dzięki spisowi treści (TOC) i przyciskom umożliwiającym zwijanie i rozwijanie bloków kodu.

DANE WYJŚCIOWE (OUTPUT):

System generuje raport HTML, który zawiera:

- a) graficzną chmurę słów
- b) wykres obrazujący dynamikę użycia wybranych słów-kluczy, haseł na tle krzywej inflacji i kluczowych wydarzeń geopolitycznych (pandemia, wybory)
- c) dynamiczny wykres obrazujący do 15 słów o najwyższym współczynniku korelacji z wybranym przez użytkownika terminem, wraz z etykietami wartości
- d) wykaz źródeł wygenerowany automatycznie z pliku wejściowego

6. SŁOWNICTWO DOKUMENTACJI

Text mining – eksploracyjna analiza danych, ogólna nazwa metod eksploracji danych służących do wydobywania danych z tekstu i ich późniejszej obróbki

Korpus – zbiór dokumentów tekstowych używany do analizy (tu: transkrypcje konferencji prasowych prezesa NBP)

Token – pojedyncza jednostka tekstu uzyskana w wyniku tokenizacji (słowo, bądź u nas utarte sformułowanie instytucjonalne lub makroekonomiczne)

Tokenizacja – proces dzielenia ciągłego tekstu na mniejsze niezależne jednostki

Heurystyka – (patrz: Cele systemu, automatyczna izolacja kluczowych danych) uproszczona metoda oparta na intuicyjnym założeniu (tu: mówca o największej częstotliwości wypowiedzi to prezes NBP)

udpipe – zaawansowane narzędzie do przetwarzania języka naturalnego, umożliwiające m.in. tokenizację, tagowanie części mowy oraz kontekstową lematyzację. Opracowane przez Instytut Lingwistyki Formalnej i Stosowanej na Uniwersytecie Karola w Pradze.

Lematyzacja – proces polegający na sprowadzeniu odmienionej formy wyrazu do jej postaci podstawowej, czyli lematu

UPOS – (patrz: Wymagania funkcjonalne) międzynarodowy standard znakowania części mowy

Stopwords – słowa nieznaczące, lista pospolitych słów, które niosą minimalną wartość semantyczną i interpretacyjną

Bag of Words – uproszczony model reprezentacji tekstu, w którym dokument traktowany jest jako zbiór pojedynczych słów

TDM – macierz dokument-termin, w której wiersze reprezentują unikalne słowa/lematy z całego korpusu, a kolumny to poszczególne dokumenty (tu: transkrypcje z konferencji). Wartości w komórkach oznaczają liczbę wystąpień danego słowa w danym dokumencie.

Asocjacje – związki współwystępowania słów w obrębie tych samych dokumentów określone przez współczynnik korelacji

Korelacja Pearsona – miara statystyczna przyjmująca wartości z przedziału $[-1, 1]$, określająca siłę i kierunek liniowego związku między słowami

Chmura słów – graficzna prezentacja najczęściej występujących słów w korpusie, im większa czcionka, tym częściej pojawia się dane słowo

Wielowątkowość – (patrz: Wymagania niefunkcjonalne, wydajność) rozbięcie zadania obliczeniowego na podzadania i jednoczesne wykonanie ich na wielu rdzeniach procesora

7. PRZYPADKI UŻYCIA (USE CASES)

A. WCZYTANIE I FILTRACJA DANYCH

- Aktor: Użytkownik systemu
- Opis: Użytkownik inicjuje proces przetwarzania plików z transkrypcjami konferencji prasowych prezesa NBP. System skanuje odpowiedni katalog, odczytuje pliki tekstowe, stosuje heurystykę zliczania znaczników mówców w celu wykrycia tego najaktywniejszego i odrzuca wypowiedzi pozostałych osób.
- Warunek początkowy: Pliki z transkrypcjami konferencji w formacie .txt znajdują się w odpowiednim katalogu/folderze.
- Wynik: Tekst wypowiedzi prezesa NBP zostaje połączony chronologicznie i załadowany do pamięci operacyjnej jako wektor korpusu.

B. ANALIZA DANYCH

- Aktor: Użytkownik systemu
- Opis: Użytkownik uruchamia dalszą część kodu. System przeprowadza wielowątkową tokenizację i lematyzację, odrzuca szum gramatyczny, konsoliduje utarte frazy instytucjonalne i makroekonomiczne oraz usuwa stopwords. Na koniec dane są transformowane do postaci macierzy TDM.
- Warunek początkowy: Wektor korpusu został poprawnie utworzony w pamięci systemu.
- Wynik: System generuje macierz TDM i wylicza bazowe statystyki częstości.

C. GENEROWANIE INTERAKTYWNEGO RAPORTU

- Aktor: Użytkownik systemu
- Opis: Użytkownik żąda wygenerowania raportu. System kompiluje dokument do formatu HTML i uruchamia serwer Shiny. Użytkownik za pomocą interfejsu może wybrać interesujące go słowo i modyfikować próg korelacji Pearsona przy użyciu suwaka. System dynamicznie przelicza i wizualizuje powiązania na wykresie.
- Warunek początkowy: Macierz TDM została utworzona, a biblioteka Shiny jest zainicjowana.
- Wynik: Wygenerowany zostaje dynamiczny i czytelny raport HTML zawierający: statyczną chmurę słów, wykres liniowy na tle historycznej inflacji i interaktywny wykres korelacji.

Schemat użycia (podział ról system/użytkownik): System automatycznie i bez udziału użytkownika realizuje większość kroków, tj. wczytuje pliki, identyfikuje najaktywniejszego mówcę i izoluje jego wypowiedzi, wykonuje lematyzację, czyści dane, tworzy macierz TDM i wizualizuje wyniki. Użytkownik z kolei wchodzi w interakcje na zasadzie: uruchomienia skryptu i korzystania z interaktywnego wykresu.

(PRZYKŁADOWE) Testowe przypadki użycia:

1. Test z poprawnymi plikami .txt w odpowiednim katalogu
2. Test sprawdzający działanie pamięci podręcznej
3. Test konsolidacji wyrażień takich jak “rada polityki pieniężnej” czy “punkt procentowy”
4. Test generowania chmury słów dla całego korpusu
5. Test wyszukiwania asocjacji dla wybranych słów przy różnych poziomach progu

8. SCENARIUSZE UŻYTKOWNIKA (USER STORIES)

Scenariusz 1:

Jako: Analityk rynków finansowych

Chcę: Przeanalizować pełny zbiór wypowiedzi prezesa NBP na konferencjach prasowych z lat 2016-2026 załadowany z plików tekstowych

Aby: Zidentyfikować najpopularniejsze pojęcia ekonomiczne używane w trakcie całej kadencji i określić główny profil komunikacyjny banku

Kryteria akceptacji:

- Skrypt automatycznie izoluje wypowiedzi prezesa NBP
- Skrypt poprawnie lematyzuje słowa, usuwa stopwords i szum gramatyczny
- System generuje chmurę słów dla całego korpusu

Scenariusz 2:

Jako: Dziennikarz

Chcę: Prześledzić częstość używania specyficznych słów na przestrzeni lat

Aby: Zrozumieć, jak narracja prezesa NBP reagowała na kryzysy gospodarcze i wydarzenia polityczne

Kryteria akceptacji:

- Skrypt poprawnie mapuje daty z nazw plików jako oś czasu
- Skrypt zaznacza lukę informacyjną wynikającą z braku konferencji w okresie pandemii
- System generuje wykres liniowy pokazujący dynamikę użycia wybranych słów kluczowych

Scenariusz 3:

Jako: Student II E

Chcę: Zbadać, które słowa w wypowiedziach prezesa NBP są najsilniej powiązane z kluczowymi terminami, takimi jak np. "inflacja"

Aby: Odkryć zależności w retoryce prowadzonej przez NBP

Kryteria akceptacji:

- Skrypt oblicza korelacje Pearsona dla słów, które wystąpiły w macierzy minimum 10 razy

- Użytkownik może dynamicznie zmieniać szukane słowo i próg akceptacji
- Wyniki są prezentowane w postaci wykresu dla maksymalnie 15 najsilniejszych powiązań

Imię i nazwisko	Zakres pracy
Michał Kośka	Przygotowanie danych do analizy, stworzenie fragmentu kodu (do zakładki nr 5)
Alicja Topór	Wykonanie fragmentu kodu dot. asocjacji, opracowanie wizualne i estetyczne raportu
Jakub Pańczak	Opracowanie dokumentacji i specyfikacji wymagań, przygotowanie statycznego raportu HTML